

Estadística Actuarial Práctica 2 - Solución

Leonel Fernando Nabaza Ruibal

Apartado 1 (3 puntos).

En ATENEA descarga la base de datos que te corresponde según el listado proporcionado (basedXX.csv). Dicha base de datos contiene sólo una variable con el número de siniestros de un asegurado en un año. Ajusta una Poisson, Binomial Negativa, Poisson Cero Inflada y Poisson Zero Modificada. Esta última, se define como el producto de dos v.a. independientes, de modo que $X = (1-Z)*(Y+1)$, donde Z es Bernouilli(prob) y Y es Poisson(lambda). Puedes utilizar el código How to define a Zero Modified Poisson distribution in R (disponible en ATENEA). Para cada distribución calcula la probabilidad de cero siniestros, así como la esperanza y varianza del número de siniestros usando los parámetros estimados. ¿Qué distribución se ajusta mejor? Razona tu respuesta.

Solución

Cargamos la base based7.csv.

```
based7 <- read.csv("based7.csv", header = FALSE)
nclaims <- based7[, 1]
```

```
summary(nclaims)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  0.000   0.000   0.000   0.398   1.000   4.000
```

```
table(nclaims)
```

```
## nclaims
##      0      1      2      3      4
## 3371 1226  258   62    8
```

```
mean(nclaims)
```

```
## [1] 0.3979695
```

```
var(nclaims)
```

```
## [1] 0.439476
```

La variable representa recuentos de siniestros. Por tanto, el primer modelo natural es una Poisson. En una Poisson se cumple que

$$E[X] = Var[X] = \lambda.$$

Sin embargo, si la varianza muestral es mayor que la media muestral, hay indicios de sobredispersión y puede ser preferible una Binomial Negativa o un modelo con modificación en cero.

Ajuste Poisson

```
lambda_pois <- mean(nclaims)

prob0_pois <- dpois(0, lambda = lambda_pois)
esp_pois <- lambda_pois
var_pois <- lambda_pois

loglik_pois <- sum(dpois(nclaims, lambda = lambda_pois, log = TRUE))
aic_pois <- -2 * loglik_pois + 2 * 1

c(lambda = lambda_pois,
  prob0 = prob0_pois,
  esperanza = esp_pois,
  varianza = var_pois,
  AIC = aic_pois)
```

##	lambda	prob0	esperanza	varianza	AIC
##	0.3979695	0.6716825	0.3979695	0.3979695	8164.4998021

Ajuste Binomial Negativa

La Binomial Negativa permite sobredispersión, ya que

$$Var[X] = \mu + \frac{\mu^2}{size}.$$

```
fit_nb <- fitdistr(nclaims, densfun = "negative binomial")
fit_nb

##      size      mu
## 3.81578113 0.39797283
## (0.90754032) (0.00944638)

size_nb <- as.numeric(fit_nb$estimate["size"])
mu_nb <- as.numeric(fit_nb$estimate["mu"])
prob_nb <- size_nb / (size_nb + mu_nb)

prob0_nb <- dnbinom(0, size = size_nb, mu = mu_nb)
esp_nb <- mu_nb
var_nb <- mu_nb + mu_nb^2 / size_nb

loglik_nb <- sum(dnbinom(nclaims, size = size_nb, mu = mu_nb, log = TRUE))
aic_nb <- -2 * loglik_nb + 2 * 2

c(size = size_nb,
  mu = mu_nb,
  prob = prob_nb,
  prob0 = prob0_nb,
  esperanza = esp_nb,
  varianza = var_nb,
  AIC = aic_nb)
```

##	size	mu	prob	prob0	esperanza	varianza
##	3.8157811	0.3979728	0.9055539	0.6848482	0.3979728	0.4394800

```
##          AIC
## 8143.1940156
```

Ajuste Poisson Cero Inflada

El modelo Poisson cero inflado mezcla una masa adicional en cero con una Poisson:

$$P(X = 0) = \pi + (1 - \pi)e^{-\lambda},$$

$$E[X] = (1 - \pi)\lambda.$$

```
datos_zip <- data.frame(nclaims = nclaims)

fit_zip <- zeroinfl(nclaims ~ 1 | 1, data = datos_zip, dist = "poisson")
summary(fit_zip)

##
## Call:
## zeroinfl(formula = nclaims ~ 1 | 1, data = datos_zip, dist = "poisson")
##
## Pearson residuals:
##      Min       1Q   Median       3Q      Max
## -0.6054 -0.6054 -0.6054  0.9159  5.4798
##
## Count model coefficients (poisson with log link):
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.72633    0.04789  -15.16   <2e-16 ***
##
## Zero-inflation model coefficients (binomial with logit link):
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.5354     0.2412  -6.365 1.96e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Number of iterations in BFGS optimization: 14
## Log-likelihood: -4072 on 2 Df

coef_zip <- coef(fit_zip)
lambda_zip <- exp(coef_zip[grepl("^count_", names(coef_zip))][1])
pi_zip <- plogis(coef_zip[grepl("^zero_", names(coef_zip))][1])

prob0_zip <- pi_zip + (1 - pi_zip) * exp(-lambda_zip)
esp_zip <- (1 - pi_zip) * lambda_zip
var_zip <- (1 - pi_zip) * lambda_zip * (1 + pi_zip * lambda_zip)
aic_zip <- AIC(fit_zip)

c(lambda = lambda_zip,
  pi = pi_zip,
  prob0 = prob0_zip,
  esperanza = esp_zip,
  varianza = var_zip,
  AIC = aic_zip)
```

```
##      lambda.count_(Intercept)      pi.zero_(Intercept)
##              0.4836823              0.1772088
##      prob0.zero_(Intercept) esperanza.zero_(Intercept)
##              0.6844670              0.3979695
##      varianza.zero_(Intercept)      AIC
##              0.4320806              8147.3937327
```

Ajuste Poisson Zero Modificada

El enunciado define

$$X = (1 - Z)(Y + 1),$$

donde $Z \sim \text{Bernoulli}(prob)$ y $Y \sim \text{Poisson}(\lambda)$, independientes. Por tanto,

$$P(X = 0) = prob,$$

$$E[X] = (1 - prob)(\lambda + 1),$$

$$\text{Var}[X] = (1 - prob)\lambda + prob(1 - prob)(\lambda + 1)^2.$$

La función de probabilidad es:

$$P(X = 0) = prob,$$

$$P(X = x) = (1 - prob)P(Y = x - 1), \quad x = 1, 2, \dots$$

```
# Función de masa de la Poisson Zero Modificada definida en el enunciado
# X = (1-Z)*(Y+1), Z Bernoulli(prob), Y Poisson(lambda)
dzmpois <- function(x, lambda, prob, log = FALSE) {
  dens <- ifelse(x == 0,
                 prob,
                 (1 - prob) * dpois(x - 1, lambda = lambda))
  if (log) log(dens) else dens
}

# Log-verosimilitud negativa para optimizar
negloglik_zm <- function(par, x) {
  lambda <- exp(par[1])
  prob <- plogis(par[2])
  -sum(dzmpois(x, lambda = lambda, prob = prob, log = TRUE))
}

# Valores iniciales razonables
prob_ini <- mean(nclaims == 0)
lambda_ini <- max(mean(nclaims[nclaims > 0]) - 1, 0.01)

fit_zm <- optim(par = c(log(lambda_ini), qlogis(prob_ini)),
               fn = negloglik_zm,
               x = nclaims,
```

```

        hessian = TRUE)

lambda_zm <- exp(fit_zm$par[1])
prob_zm <- plogis(fit_zm$par[2])

prob0_zm <- prob_zm
esp_zm <- (1 - prob_zm) * (lambda_zm + 1)
var_zm <- (1 - prob_zm) * lambda_zm + prob_zm * (1 - prob_zm) * (lambda_zm + 1)^2
loglik_zm <- -fit_zm$value
aic_zm <- -2 * loglik_zm + 2 * 2

c(lambda = lambda_zm,
  prob = prob_zm,
  prob0 = prob0_zm,
  esperanza = esp_zm,
  varianza = var_zm,
  AIC = aic_zm)

##      lambda      prob      prob0  esperanza  varianza      AIC
## 0.2612613 0.6844670 0.6844670 0.3979695 0.4260004 8161.5581582

```

Comparación de modelos

```

tabla_ap1 <- data.frame(
  Modelo = c("Poisson", "Binomial Negativa", "Poisson Cero Inflada", "Poisson Zero Modificada"),
  Probabilidad_cero = c(prob0_pois, prob0_nb, prob0_zip, prob0_zm),
  Esperanza = c(esp_pois, esp_nb, esp_zip, esp_zm),
  Varianza = c(var_pois, var_nb, var_zip, var_zm),
  AIC = c(aic_pois, aic_nb, aic_zip, aic_zm)
)

kable(tabla_ap1, digits = 5)

```

Modelo	Probabilidad_cero	Esperanza	Varianza	AIC
Poisson	0.67168	0.39797	0.39797	8164.500
Binomial Negativa	0.68485	0.39797	0.43948	8143.194
Poisson Cero Inflada	0.68447	0.39797	0.43208	8147.394
Poisson Zero Modificada	0.68447	0.39797	0.42600	8161.558

La distribución que se ajusta mejor es la que presenta menor AIC. Además, es importante comprobar si el modelo reproduce adecuadamente la elevada proporción de ceros observada en los datos. En este caso, el modelo Poisson infraestima la probabilidad de cero siniestros, mientras que la Binomial Negativa, la Poisson cero inflada y la Poisson zero-modified proporcionan valores muy similares y más cercanos a la realidad. Entre ellos, la Binomial Negativa presenta el menor AIC y, además, permite capturar la sobredispersión observada (varianza mayor que la media), por lo que resulta el modelo más adecuado.

Apartado 2 (3 puntos).

Se proporciona el archivo `datatime.csv` (datos ficticios) que contiene datos sobre asegurados jóvenes que contratan una póliza telemática. La base de datos `datatime.csv` nos proporciona información sobre el tiempo que tardan en tener su primer siniestro. Las variables son las siguientes:

Variables	Descripción
time	tiempo transcurrido desde que contratan la póliza telemática hasta que tienen el primer siniestro, en años
status	0 (censura), 1 (evento)
x1	1 = conducción urbana por encima del 25 por ciento, 0 = conducción urbana igual al 25 por ciento como máximo
x2	1 = excesos de velocidad por encima del 8 por ciento, 0 = excesos de velocidad igual al 8 por ciento como máximo
x3	1 = uso principal del vehículo (laboral, estudios), 0 = uso principal del vehículo (ocio)

Realiza los siguientes cálculos:

- Haz una estimación de la función de supervivencia para todos los asegurados usando Kaplan y Meier. ¿Cuál es la probabilidad de que un asegurado tarde más de seis meses en tener su primer siniestro? ¿y de que tarde más de un año?
- Haz una estimación de la función de supervivencia para los diferentes grupos definidos por x1 usando Kaplan y Meier. Representa gráficamente las curvas de supervivencia. Haz un test para ver si hay diferencias significantivas en las curvas de supervivencia de ambos grupos definidos por x1. Interpreta los resultados.
- Estima un modelo de Weibull para time en función de x1, x2 y x3. Interpreta los resultados. ¿Cuál es el factor de aceleración de x1? qué interpretación tiene? A partir del modelo de Weibull estimado, calcula, para estos dos asegurados, la probabilidad de que el tiempo hasta el primer accidente sea inferior al año, así como el tiempo esperado hasta el primer accidente:

Variables	Primer_asegurado	Segundo_asegurado
x1	0	0
x2	0	1
x3	1	1

- Estima un modelo de Cox para time en función de x1, x2 y x3. Interpreta los resultados.
- Utilizando el modelo de Cox que has ajustado, haz una representación de las curvas de supervivencia de los dos asegurados del apartado c). ¿Cuál sería la probabilidad de que tarden más de medio año en tener su primer siniestro?
- ¿Se cumple la hipótesis de proporcionalidad en el modelo de Cox que has ajustado? En caso de que no se cumpla, se te ocurre alguna forma de solucionar el problema?

Solución

```
datetime <- read.csv("datetime.csv", sep = ";", dec = ",")
str(datetime)
```

```
## 'data.frame': 422 obs. of 5 variables:
## $ time : num 1.779 0.699 0.085 0.138 2.119 ...
## $ status: int 0 1 1 1 1 1 1 1 1 1 ...
## $ x1 : int 1 0 1 1 0 0 1 0 1 0 ...
## $ x2 : int 0 0 1 1 0 0 1 0 1 0 ...
## $ x3 : int 0 0 1 0 0 0 1 1 1 1 ...
```

```
summary(datatime)
```

```
##           time           status           x1           x2
## Min.      :0.0030   Min.      :0.0000   Min.      :0.0000   Min.      :0.0000
## 1st Qu.:0.0730   1st Qu.:1.0000   1st Qu.:0.0000   1st Qu.:0.0000
## Median :0.2770   Median :1.0000   Median :1.0000   Median :1.0000
## Mean     :0.7821   Mean     :0.7536   Mean     :0.5498   Mean     :0.5071
## 3rd Qu.:1.1210   3rd Qu.:1.0000   3rd Qu.:1.0000   3rd Qu.:1.0000
## Max.     :4.3620   Max.     :1.0000   Max.     :1.0000   Max.     :1.0000
##           x3
## Min.      :0.0000
## 1st Qu.:0.0000
## Median :1.0000
## Mean     :0.5592
## 3rd Qu.:1.0000
## Max.     :1.0000
```

a) Kaplan-Meier global

La función de supervivencia es

$$S(t) = P(T > t).$$

Por tanto, la probabilidad de tardar más de seis meses es $S(0.5)$, y la probabilidad de tardar más de un año es $S(1)$.

Estimación de la función de supervivencia

El estimador de Kaplan-Meier permite estimar la función de supervivencia definida como:

$$S(t) = P(T > t)$$

Bajo censura por la derecha, el estimador de Kaplan-Meier se define como:

$$\hat{S}(t) = \prod_{t_j \leq t} \left(1 - \frac{d_j}{R_j}\right)$$

donde d_j es el número de eventos en el instante t_j y R_j es el número de individuos en riesgo justo antes de t_j .

```
km_global <- survfit(Surv(time, status) ~ 1, data = datatime)
km_global
```

```
## Call: survfit(formula = Surv(time, status) ~ 1, data = datatime)
##
##           n events median 0.95LCL 0.95UCL
## [1,] 422      318  0.346   0.262   0.465
```


```
summary(km_global, times = c(0.5, 1))
```

```
## Call: survfit(formula = Surv(time, status) ~ 1, data = datatime)
##
##   time n.risk n.event survival std.err lower 95% CI upper 95% CI
##   0.5   173    233   0.435  0.0246   0.390   0.486
##   1.0   120     40   0.329  0.0236   0.286   0.379
```

```
S_global <- summary(km_global, times = c(0.5, 1))$surv

plot(km_global,
     xlab = "Tiempo desde la contratación",
     ylab = "S(t)",
     main = "Función de supervivencia Kaplan-Meier")
```

Función de supervivencia Kaplan-Meier



```
c(S_0.5 = S_global[1], S_1 = S_global[2])
```

```
##      S_0.5      S_1
## 0.4352395 0.3290931
```

La probabilidad estimada de que un asegurado tarde más de seis meses en tener el primer siniestro es 0.43524.
La probabilidad estimada de que tarde más de un año es 0.32909.

b) Kaplan-Meier por grupos de x1 y test log-rank


```
km_x1 <- survfit(Surv(time, status) ~ x1, data = datatime)
summary(km_x1, times = c(0.5, 1))
```

```
## Call: survfit(formula = Surv(time, status) ~ x1, data = datatime)
##
##              x1=0
##  time n.risk n.event survival std.err lower 95% CI upper 95% CI
##  0.5    95     87   0.533  0.0367   0.466   0.610
##  1.0    69     25   0.391  0.0363   0.325   0.469
##
```

```
##               x1=1
## time n.risk n.event survival std.err lower 95% CI upper 95% CI
##  0.5    78   146   0.355  0.0321    0.297    0.423
##  1.0    51    15   0.280  0.0306    0.226    0.347
```

```
plot(km_x1,
     col = c(1, 2),
     lty = 1,
     xlab = "Tiempo desde la contratación",
     ylab = "S(t)",
     main = "Kaplan-Meier por grupos de x1")
legend("topright",
     legend = c("x1 = 0", "x1 = 1"),
     col = c(1, 2),
     lty = 1)
```

Kaplan-Meier por grupos de x1



Para comprobar si las curvas son significativamente distintas usamos el test log-rank:

$$H_0 : S_0(t) = S_1(t).$$

```
test_logrank <- survdiff(Surv(time, status) ~ x1, data = datatime)
test_logrank
```

```
## Call:
## survdiff(formula = Surv(time, status) ~ x1, data = datatime)
##
##      N Observed Expected (O-E)^2/E (O-E)^2/V
```

```
## x1=0 190      139      170      5.75      12.7
## x1=1 232      179      148      6.64      12.7
##
## Chisq= 12.7 on 1 degrees of freedom, p= 4e-04
```

```
p_logrank <- 1 - pchisq(test_logrank$chisq, df = length(test_logrank$n) - 1)
p_logrank
```

```
## [1] 0.0003668337
```

Como el p-valor es 3.67×10^{-4} , es menor que 0.05. Por lo tanto, se rechaza la igualdad de curvas de supervivencia. En ese caso, hay evidencia de que el tiempo hasta el primer siniestro difiere entre los dos grupos definidos por x_1 .

c) Modelo Weibull

Ajustamos un modelo Weibull AFT:

$$\log(T) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \sigma W.$$

```
modelo_weibull <- survreg(Surv(time, status) ~ x1 + x2 + x3,
                          data = datatime,
                          dist = "weibull")
```

```
summary(modelo_weibull)
```

```
##
## Call:
## survreg(formula = Surv(time, status) ~ x1 + x2 + x3, data = datatime,
##         dist = "weibull")
##              Value Std. Error      z      p
## (Intercept)  0.9710      0.1811   5.36 8.2e-08
## x1          -0.5162      0.1595  -3.24 0.00121
## x2          -2.4884      0.1762 -14.12 < 2e-16
## x3           0.5620      0.1583   3.55 0.00039
## Log(scale)   0.3404      0.0428   7.95 1.9e-15
##
## Scale= 1.41
##
## Weibull distribution
## Loglik(model)= -102.9  Loglik(intercept only)= -224.2
## Chisq= 242.57 on 3 degrees of freedom, p= 2.6e-52
## Number of Newton-Raphson Iterations: 5
## n= 422
```

En el modelo Weibull AFT, los coeficientes se interpretan sobre el logaritmo del tiempo. El factor de aceleración de una covariable es $\exp(\beta)$. Si es menor que 1, acorta el tiempo hasta el siniestro; si es mayor que 1, lo alarga.

```
factores_aceleracion <- exp(coef(modelo_weibull))
factores_aceleracion
```

```
## (Intercept)          x1          x2          x3
## 2.64064807 0.59675437 0.08303864 1.75413358
```

```
factor_x1 <- exp(coef(modelo_weibull)["x1"])
factor_x1
```

```
##          x1
## 0.5967544
```

El factor de aceleración asociado a x_1 es 0.59675. Esto significa que, manteniendo constantes las demás variables, pasar de $x_1 = 0$ a $x_1 = 1$ multiplica el tiempo hasta el primer siniestro por ese factor. Por lo tanto, x_1 acorta el tiempo para el primer accidente.

Predicción para los dos asegurados indicados:

```
nuevo <- data.frame(
  x1 = c(0, 0),
  x2 = c(0, 1),
  x3 = c(1, 1)
)

lp_weib <- predict(modelo_weibull, newdata = nuevo, type = "lp")
sigma_weib <- modelo_weibull$scale
shape_weib <- 1 / sigma_weib
scale_weib <- exp(lp_weib)

prob_T_menor_1 <- pweibull(1, shape = shape_weib, scale = scale_weib)
esperanza_T <- scale_weib * gamma(1 + 1 / shape_weib)

tabla_pred_weibull <- data.frame(
  Asegurado = c("Primer asegurado", "Segundo asegurado"),
  x1 = nuevo$x1,
  x2 = nuevo$x2,
  x3 = nuevo$x3,
  Prob_T_menor_1 = prob_T_menor_1,
  Tiempo_esperado = esperanza_T
)

kable(tabla_pred_weibull, digits = 5)
```

Asegurado	x1	x2	x3	Prob_T_menor_1	Tiempo_esperado
Primer asegurado	0	0	1	0.28536	5.77457
Segundo asegurado	0	1	1	0.86102	0.47951

d) Modelo de Cox

El modelo de Cox viene dado por

$$h(t|x) = h_0(t) \exp(x'\beta).$$

```
modelo_cox <- coxph(Surv(time, status) ~ x1 + x2 + x3, data = datetime)
summary(modelo_cox)
```

```
## Call:
## coxph(formula = Surv(time, status) ~ x1 + x2 + x3, data = datetime)
##
##      n= 422, number of events= 318
##
##      coef exp(coef) se(coef)      z Pr(>|z|)
## x1  0.3251    1.3841   0.1161  2.801  0.00510 **
```

```
## x2  1.6553      5.2347    0.1258 13.162 < 2e-16 ***
## x3 -0.3702      0.6906    0.1132 -3.271 0.00107 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##      exp(coef) exp(-coef) lower .95 upper .95
## x1      1.3841      0.7225      1.1025      1.7377
## x2      5.2347      0.1910      4.0911      6.6980
## x3      0.6906      1.4480      0.5532      0.8621
##
## Concordance= 0.732  (se = 0.013 )
## Likelihood ratio test= 211.9 on 3 df,  p=<2e-16
## Wald test               = 194.9 on 3 df,  p=<2e-16
## Score (logrank) test = 229.8 on 3 df,  p=<2e-16

hazard_ratios <- exp(coef(modelo_cox))
hazard_ratios
```

```
##          x1          x2          x3
## 1.3841443 5.2347361 0.6906077
```

Un hazard ratio mayor que 1 indica que la variable aumenta el riesgo instantáneo de tener el primer siniestro. Un hazard ratio menor que 1 indica que reduce el riesgo.

Para x1 el hazard ratio es 1.384, por lo que los asegurados con conducción urbana superior al 25% presentan un riesgo instantáneo de tener el primer siniestro aproximadamente un 38.4% mayor que aquellos con menor conducción urbana, manteniendo el resto de variables constantes.

Para x2 el hazard ratio es 5.235, lo que indica que los asegurados con exceso de velocidad superior al 8% presentan un riesgo de siniestro más de 5 veces mayor que los que no superan ese umbral. Se trata del factor con mayor impacto sobre el riesgo.


Para x3 el hazard ratio es 0.691, por lo que los asegurados cuyo uso del vehículo es laboral o de estudios presentan un riesgo de siniestro aproximadamente un 30.9% menor que aquellos que lo usan principalmente para ocio.

e) Curvas de supervivencia de los dos asegurados con el modelo de Cox

```
sf_cox <- survfit(modelo_cox, newdata = nuevo)

plot(sf_cox,
     col = c(1, 2),
     lty = 1,
     xlab = "Tiempo desde la contratación",
     ylab = "S(t)",
     main = "Curvas de supervivencia predichas con Cox")
legend("topright",
     legend = c("Primer asegurado", "Segundo asegurado"),
     col = c(1, 2),
     lty = 1)
```

Curvas de supervivencia predichas con Cox



```
summary(sf_cox, times = 0.5)
```

```
## Call: survfit(formula = modelo_cox, newdata = nuevo)
##
##   time n.risk n.event survival1 survival2
##   0.5   173   233    0.778    0.269
```

```
S_05_cox <- summary(sf_cox, times = 0.5)$surv
```

```
tabla_pred_cox <- data.frame(
  Asegurado = c("Primer asegurado", "Segundo asegurado"),
  Prob_T_mayor_0.5 = S_05_cox
)
```

```
kable(tabla_pred_cox, digits = 5)
```

Asegurado	Prob_T_mayor_0.5.1	Prob_T_mayor_0.5.2
Primer asegurado	0.77822	0.26913
Segundo asegurado	0.77822	0.26913


f) Hipótesis de proporcionalidad


La hipótesis de proporcionalidad se puede comprobar con los residuos de Schoenfeld.


```
test_ph <- cox.zph(modelo_cox)
test_ph
```

```
##      chisq df      p
## x1    0.879  1 0.349
## x2    4.951  1 0.026
## x3    0.953  1 0.329
## GLOBAL 6.632  3 0.085
```

```
plot(test_ph)
```







El contraste global presenta un p-valor de 0.085, por lo que no se rechaza la hipótesis de proporcionalidad al nivel del 5%.

Analizando las covariables individualmente, se observa que x1 y x3 no presentan evidencia de violación de la hipótesis, mientras que la variable x2 muestra un p-valor de 0.026, lo que sugiere una posible desviación de la proporcionalidad.

Sin embargo, dado que el test global no es significativo, el modelo de Cox puede considerarse adecuado en conjunto, aunque el efecto de x2 podría variar ligeramente en el tiempo.

Por otra parte, si alguna variable incumple la hipótesis, se puede considerar una estratificación o introducir efectos dependientes del tiempo. Por ejemplo, si x2 no cumple la hipótesis:

```
modelo_cox_estratificado <- coxph(Surv(time, status) ~ x1 + x3 + strata(x2),
                                   data = datetime)
summary(modelo_cox_estratificado)
```

```
## Call:
## coxph(formula = Surv(time, status) ~ x1 + x3 + strata(x2), data = datetime)
##
##   n= 422, number of events= 318
##
##           coef exp(coef) se(coef)      z Pr(>|z|)
## x1  0.3087     1.3617   0.1170   2.638  0.00834 **
## x3 -0.3619     0.6963   0.1133  -3.195  0.00140 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##      exp(coef) exp(-coef) lower .95 upper .95
```

```
## x1      1.3617      0.7344      1.0826      1.7127
## x3      0.6963      1.4361      0.5577      0.8694
##
## Concordance= 0.573 (se = 0.017 )
## Likelihood ratio test= 17.05 on 2 df, p=2e-04
## Wald test              = 17.04 on 2 df, p=2e-04
## Score (logrank) test = 17.19 on 2 df, p=2e-04
```

Apartado 3 (4 puntos).

La base de datos COSTE.CSV contiene datos de costes de siniestros (variable X). Se pide:

- Si se estableciera una franquicia ordinaria de 400 euros, ¿cuál es la media y varianza del coste de los siniestros, teniendo sólo en cuenta los casos en los que efectivamente la compañía llega a pagar una indemnización?
- Ajusta una distribución Gamma a los costes que hay en la base de datos COSTES.CSV, ¿crees que se ajusta bien?
- Consideramos ahora la distribución Gamma que has ajustado en b) para el coste e imagina que se introduce una franquicia ordinaria de 400 euros a ese coste. Si tiene lugar un siniestro (del importe que sea), ¿cuál es la probabilidad de que la compañía no tenga que pagar nada?

Ahora, definimos la variable excess loss $Y_p = (X - 400 | X > 400)$ donde X es Gamma con los parámetros que has obtenido al hacer el ajuste del apartado a). Se pide:

- Representa la función de densidad y de distribución de X y de Y_p .
- ¿Cuál es la probabilidad de que Y_p esté entre 200 y 600? ¿Cómo calcularías esta probabilidad usando únicamente la función pgamma?
- Calcula el percentil 95 de Y_p
- Imaginemos que la compañía también desea establecer un límite máximo a la indemnización que afecte al 5 por ciento de los siniestros más caros (teniendo en cuenta los costes originales). ¿Dónde se establecería ese límite? Será mayor, igual o menor que el valor calculado en f)? Por qué?
- Representa gráficamente la función de distribución de Y_p (excess loss con franquicia ordinaria de 400 euros), aplicando también el límite a los costes originales que has calculado en g). Interpreta el gráfico obtenido. ¿Con qué probabilidad el valor de Y_p quedará limitado por arriba?


Solución

```
coste <- read.csv("coste.csv", sep = ";", dec = ",")
X <- coste$x

summary(X)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   95.26  702.87  933.59 1010.99 1240.94 2731.57

hist(X, breaks = 30, main = "Histograma de costes", xlab = "Coste")
```



a) Franquicia ordinaria de 400 euros

Con franquicia ordinaria $d = 400$, la variable por pago es

$$Y^P = X - d \mid X > d.$$

```
d <- 400
Yp_emp <- X[X > d] - d

media_Yp_emp <- mean(Yp_emp)
var_Yp_emp <- var(Yp_emp)

c(media = media_Yp_emp, varianza = var_Yp_emp)
```

```
##      media      varianza
## 643.1422 184338.8486
```

La media empírica de los pagos positivos es 643.1422 y la varianza empírica es 1.8433885×10^5 .

b) Ajuste Gamma

La distribución Gamma es adecuada para costes positivos y asimétricos. Ajustamos los parámetros por máxima verosimilitud.

```
fit_gamma <- fitdistr(X, densfun = "gamma")
fit_gamma
```

```
##          shape          rate
## 5.2181106278 0.0051613659
## (0.3274367410) (0.0003335346)

shape_hat <- as.numeric(fit_gamma$estimate["shape"])
rate_hat <- as.numeric(fit_gamma$estimate["rate"])
scale_hat <- 1 / rate_hat


media_gamma <- shape_hat * scale_hat
var_gamma <- shape_hat * scale_hat^2

c(shape = shape_hat,
  rate = rate_hat,
  scale = scale_hat,
  media = media_gamma,
  varianza = var_gamma)

##          shape          rate          scale          media          varianza
## 5.218111e+00 5.161366e-03 1.937472e+02 1.010994e+03 1.958772e+05
```

Representamos el histograma junto con la densidad ajustada.

```
hist(X, breaks = 30, freq = FALSE,
     main = "Ajuste Gamma a los costes",
     xlab = "Coste")
curve(dgamma(x, shape = shape_hat, rate = rate_hat),
      add = TRUE,
      lwd = 2)
```



Comprobamos el ajuste con el test de Kolmogorov-Smirnov.

```
ks_gamma <- ks.test(X, "pgamma", shape = shape_hat, rate = rate_hat)
ks_gamma
```

```
##
## Asymptotic one-sample Kolmogorov-Smirnov test
##
## data: X
## D = 0.035168, p-value = 0.7307
## alternative hypothesis: two-sided
```

Si el p-valor es mayor que 0.05, no rechazamos que los costes procedan de una distribución Gamma. En ese caso, el ajuste Gamma puede considerarse razonable.

El p-valor obtenido es 0.7307, muy superior al nivel de significación habitual del 5%, por lo que no se rechaza la hipótesis nula de que los datos siguen una distribución Gamma.

Por tanto, no existe evidencia estadística para descartar el modelo Gamma, lo que indica que proporciona un buen ajuste a los datos de coste.

c) Probabilidad de no pagar nada

Con franquicia ordinaria, la compañía no paga nada cuando

$$X \leq 400.$$

```
prob_no_pago <- pgamma(d, shape = shape_hat, rate = rate_hat)
prob_no_pago
```

```
## [1] 0.0464663
```

La probabilidad estimada de no pagar nada es 0.04647.

d) Densidad y distribución de X y de Yp

Para la variable por pago con franquicia ordinaria,

$$F_{Y^P}(y) = \frac{F_X(y + d) - F_X(d)}{1 - F_X(d)}, \quad y > 0,$$


$$f_{Y^P}(y) = \frac{f_X(y + d)}{1 - F_X(d)}, \quad y > 0.$$

```
fYp <- function(y) {
  dgamma(y + d, shape = shape_hat, rate = rate_hat) /
  (1 - pgamma(d, shape = shape_hat, rate = rate_hat))
}

FYp <- function(y) {
  (pgamma(y + d, shape = shape_hat, rate = rate_hat) -
   pgamma(d, shape = shape_hat, rate = rate_hat)) /
  (1 - pgamma(d, shape = shape_hat, rate = rate_hat))
}
```


```
xx <- seq(0, quantile(X, 0.995), length.out = 1000)
yy <- seq(0, quantile(Yp_emp, 0.995), length.out = 1000)

plot(xx, dgamma(xx, shape = shape_hat, rate = rate_hat),
     type = "l",
     xlab = "x",
     ylab = "Densidad",
     main = "Densidad de X")
```




```
plot(xx, pgamma(xx, shape = shape_hat, rate = rate_hat),
     type = "l",
     xlab = "x",
     ylab = "F_X(x)",
     main = "Función de distribución de X")
```

Función de distribución de X




```
plot(yy, fYp(yy),  
      type = "l",  
      xlab = "y",  
      ylab = "Densidad",  
      main = "Densidad de Yp")
```



```
plot(yy, FYp(yy),  
      type = "l",  
      xlab = "y",  
      ylab = "F_Yp(y)",  
      main = "Función de distribución de Yp")
```

Función de distribución de Yp



e) Probabilidad de que Yp esté entre 200 y 600

Queremos calcular

$$P(200 < Y^P < 600) = P(600 < X < 1000 \mid X > 400).$$

```
prob_Yp_200_600 <- FYp(600) - FYp(200)
prob_Yp_200_600
```

```
## [1] 0.3943235
```

Usando únicamente pgamma, la probabilidad se calcula como:

```
prob_Yp_200_600_pgamma <-
  (pgamma(1000, shape = shape_hat, rate = rate_hat) -
   pgamma(600, shape = shape_hat, rate = rate_hat)) /
  (1 - pgamma(400, shape = shape_hat, rate = rate_hat))
prob_Yp_200_600_pgamma
```

```
## [1] 0.3943235
```

f) Percentil 95 de Yp

El percentil 95 de Y^P es el valor q que cumple:

$$F_{Y^P}(q) = 0.95.$$

```
q95_Yp <- uniroot(function(y) FYp(y) - 0.95,
                  interval = c(0, max(X) * 10))$root
q95_Yp
```

```
## [1] 1446.573
```

El percentil 95 de la variable por pago es 1446.5735.

g) Límite máximo que afecta al 5 por ciento de los siniestros más caros

Si queremos que el límite afecte al 5 por ciento de los siniestros más caros teniendo en cuenta los costes originales, debemos calcular el percentil 95 de X :

```
limite_original <- qgamma(0.95, shape = shape_hat, rate = rate_hat)
limite_indemnizacion <- limite_original - d

c(limite_original = limite_original,
  limite_indemnizacion = limite_indemnizacion,
  percentil95_Yp = q95_Yp)
```

```
##      limite_original limite_indemnizacion      percentil95_Yp
##      1831.502      1431.502      1446.573
```

El límite sobre el coste original se establecería en 1831.5022 euros. Si se expresa como indemnización después de la franquicia, sería 1431.5022 euros.

Este valor no tiene por qué coincidir exactamente con el percentil 95 de Y^P , porque Y^P está condicionado a que $X > 400$, mientras que el límite de este apartado se calcula sobre todos los costes originales.

h) Distribución de Y_p aplicando también límite máximo

Definimos la indemnización con franquicia ordinaria y límite máximo sobre el coste original:

$$Y_L = \min(X, L) - 400 \mid X > 400,$$

con L igual al percentil 95 de los costes originales.

La función de distribución coincide con la de Y^P hasta $L - 400$, y a partir de ese punto acumula una masa de probabilidad en el límite.

```
lim <- limite_original
lim_y <- lim - d

FYp_limitada <- function(y) {
  ifelse(y < lim_y,
    FYp(y),
    1)
}

y_grid <- seq(0, q95_Yp * 1.3, length.out = 1000)


plot(y_grid, FYp(y_grid),
  type = "l",
  lwd = 2,
  xlab = "y",
  ylab = "Función de distribución",
  main = "Distribución de Yp con y sin límite")
```

```

lines(y_grid, FYp_limitada(y_grid), lty = 2, lwd = 2)
abline(v = lim_y, lty = 3)
legend("bottomright",
      legend = c("Yp sin límite", "Yp con límite", "Límite"),
      lty = c(1, 2, 3),
      lwd = c(2, 2, 1))

```

Distribución de Yp con y sin límite



```

prob_limitado_condicional <-
  (1 - pgamma(lim, shape = shape_hat, rate = rate_hat)) /
  (1 - pgamma(d, shape = shape_hat, rate = rate_hat))

prob_limitado_original <- 1 - pgamma(lim, shape = shape_hat, rate = rate_hat)

c(prob_limitado_original = prob_limitado_original,
  prob_limitado_condicionado_a_pago = prob_limitado_condicional)

```

```

##          prob_limitado_original prob_limitado_condicionado_a_pago
##                0.05000000                0.05243653

```

El gráfico muestra la función de distribución de la variable por pago Y^P con y sin límite superior.

La curva continua representa la distribución sin límite, mientras que la curva discontinua muestra la distribución cuando se introduce un límite máximo de indemnización.

Se observa que ambas distribuciones coinciden hasta el valor del límite. A partir de ese punto, la distribución con límite se vuelve constante e igual a 1, lo que refleja que todas las indemnizaciones superiores al límite quedan truncadas en dicho valor.

Este comportamiento implica una acumulación de probabilidad en el punto del límite, ya que todos los siniestros más grandes se agrupan en ese valor máximo. Esto reduce la variabilidad de los pagos y limita la exposición a siniestros extremos, aunque mantiene inalterada la distribución para indemnizaciones por debajo del límite.

En consecuencia, la introducción del límite reduce el riesgo asociado a la cola de la distribución, lo que es especialmente relevante en la gestión del riesgo de grandes siniestros.

La probabilidad de que un coste original supere el límite es 0.05, por construcción aproximadamente 0.05. Condicionando a que haya pago positivo, la probabilidad de que Y^P quede limitado por arriba es 0.05244.