

● Regresión de Poisson

- Método estadístico para analizar datos de recuento o tasas.
- Los datos son números enteros no negativos (0, 1, 2, ...).
- Ejemplos habituales:
 - Número de clientes por hora.
 - Número de llamadas recibidas al día.
 - Número de goles en un partido.
- Permite identificar qué variables explicativas influyen en la frecuencia de un evento.

● Distribución de Poisson vs Distribución Normal

La distribución de Poisson se utiliza para calcular la probabilidad de que sucedan ciertos eventos dentro de un intervalo de tiempo. Como hablamos de recuentos, los valores siempre son 0 o mayores; no puede haber números negativos de sucesos. En cambio, la distribución normal es continua, se aplica a variables continuas y puede dar tanto valores positivos como negativos.

Distribución Poisson	Distribución Normal
Se utiliza para contar datos o tasa(razón) de datos.	Usada para variables continuas
Sesgada según los valores de lambda	Curva en forma de campana que es simétrica alrededor de la media
Varianza igual que la media	La varianza y la media son parámetros diferentes; media, mediana y moda son iguales

● Implementación en R

En R, el comando `glm()` se usa para modelizar modelos lineales generalizados. Aquí está la estructura general de `glm()`:

```
glm(formula, family = familytype(link = ""), data,...)
```

formula: La fórmula es una representación simbólica de cómo se modela para ajustar.

family: La familia indica la elección de las funciones de varianza y enlace. Hay varias opciones de familia, incluidas Poisson y Logistic.

datos: Los datos son el conjunto de datos que se utilizará.

● Implementación en R

Family	Default Link Function
binomial	(link = “logit”)
gaussian	(link = “identity”)
Gamma	(link = “inverse”)
inverse.gaussian	(link = $\frac{1}{\mu^2}$)
poisson	(link = “log”)
quasi	(link = “identity,” variance = “constant”)
quasibinomial	(link = “logit”)
quasipoisson	(link = “log”)

● APLICACIÓN EN R

Pasos a seguir:

1. Ajustar un modelo GLM Poisson

2. Ver si hay sobredispersión



- Modelo errores estándar robustos
- Quasi Poisson
- Binomial Negativa

3. Predicciones del modelo

4. Diagnósis del Modelo



- Análisis de los residuos
- Puntos influyentes

● EJEMPLO

- num_awards: número de premios obtenidos por cada estudiante en un año (variable de respuesta, recuento).
- math: nota en el examen final de matemáticas (predictora continua).
- prog: tipo de programa educativo (predictora categórica):
 - 1 = General
 - 2 = Académico
 - 3 = Vocacional
- Conjunto de datos con 200 estudiantes de instituto.
- Fuente: UCLA-Stats (ejemplo clásico de regresión de Poisson).

● APLICACIÓN EN R


En una escuela secundaria, se ha recopilado información sobre el número de premios académicos que han obtenido los estudiantes en un año. Se quiere analizar qué factores influyen en la cantidad de premios ganados y si ciertas características de los estudiantes pueden predecir su desempeño en la obtención de premios.

```
summary (awards)
```


id		num_awards	prog	math
Min.	: 1.00	Min. :0.00	General : 45	Min. :33.00
1st Qu.:	50.75	1st Qu.:0.00	Academic :105	1st Qu.:45.00
Median	:100.50	Median :0.00	Vocational: 50	Median :52.00
Mean	:100.50	Mean :0.63		Mean :52.65
3rd Qu.:	150.25	3rd Qu.:1.00		3rd Qu.:59.00
Max.	:200.00	Max. :6.00		Max. :75.00

Caso Práctico

Número de Premios en función de la nota de Matemáticas



Caso Práctico



Caso Práctico

● Paso 1: Ajuste del modelo GLM Poisson

Modelo 1: `fit_glm_1 <- glm(num_awards ~ math, data=awards, family = poisson(link = "log"))`

Modelo 2: `fit_glm_2 <- glm(num_awards ~ math + prog, data=awards, family = poisson(link = "log"))`

```
summary (fit_glm_1)
```

Call:

```
glm(formula = num_awards ~ math, family = poisson, data = awards)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.333532	0.591261	-9.021	<2e-16 ***
math	0.086166	0.009679	8.902	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 287.67 on 199 degrees of freedom
Residual deviance: 204.02 on 198 degrees of freedom
AIC: 384.08

Caso Práctico

● Paso 1: Ajuste del modelo GLM Poisson

```
summary (fit_glm_2)
```

Call:

```
glm(formula = num_awards ~ math + prog, family = poisson, data = awards)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-5.24712	0.65845	-7.969	1.60e-15	***
math	0.07015	0.01060	6.619	3.63e-11	***
progAcademic	1.08386	0.35825	3.025	0.00248	**
progVocational	0.36981	0.44107	0.838	0.40179	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 287.67 on 199 degrees of freedom
Residual deviance: 189.45 on 196 degrees of freedom
AIC: 373.5

Number of Fisher Scoring iterations: 6

Caso Práctico

● Paso 1: Ajuste del modelo GLM Poisson

```
anova(fit_glm_1, fit_glm_2)
```

Analysis of Deviance Table

Model 1: num_awards ~ math

Model 2: num_awards ~ math + prog

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	198	204.02			
2	196	189.45	2	14.572	0.0006852 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

● Paso 2: ¿ Hay Sobredispersión ?

Comparación entre media y varianza

```
mean_awards <- mean(awards$num_awards)
var_awards <- var(awards$num_awards)
cat("Media de premios:", mean_awards, " - Varianza de premios:", var_awards, "\n")

Media de premios: 0.63 - Varianza de premios: 1.108643
```

Relación entre deviance y grados de libertad

```
deviance_ratio <- deviance(fit_glm_2) / df.residual(fit_glm_2)
cat("Razón Deviance/GL:", deviance_ratio, "\n")
```


● Paso 2: ¿ Hay Sobredispersión ?

```
if (deviance_ratio > 1.5) {  
  cat("Indicación de sobre-dispersión en el modelo.\n")  
} else {  
  cat("No hay evidencia fuerte de sobre-dispersión.\n")  
}
```

No hay evidencia fuerte de sobre-dispersión.

● Paso 2: ¿ Hay Sobredispersión ?

Ho: El modelo se ajusta a los datos

Ha: El modelo no se ajusta a los datos

```
with(  
  fit_glm_2,  
  cbind(  
    res.deviance = deviance,  
    df = df.residual,  
    p = pchisq(deviance, df.residual, lower.tail = FALSE)  
  )  
)
```

```
      res.deviance  df      p  
[1,]      189.4496 196 0.6182274
```

Caso Práctico

- ¿Cómo arreglar el problema de la sobredispersión?

- 1. Errores estándar robustos

```
cov.m1 <- sandwich::vcovHC(fit_glm_2, type = "HC0")
std.err <- sqrt(diag(cov.m1))
r.est <- cbind(
  Estimate = coef(fit_glm_2),
  "EE heterocedástico" = std.err,
  "Pr(>|z|)" = 2 * pnorm(abs(coef(fit_glm_2) / std.err), lower.tail = FALSE),
  LL = coef(fit_glm_2) - 1.96 * std.err,
  UL = coef(fit_glm_2) + 1.96 * std.err)
```

	Estimate	EE heterocedástico
(Intercept)	-5.2471244	0.64599839
math	0.0701524	0.01043516
progAcademic	1.0838591	0.32104816
progVocational	0.3698092	0.40041731

Caso Práctico

● 2. Modelo QuasiPoisson

```
modeliq <- glm(num_awards ~ math + prog, family = quasipoisson, data = awards)
```

```
summary(modeliq)
```

Call:

```
glm(formula = num_awards ~ math + prog, family = quasipoisson,  
    data = awards)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-5.24712	0.68503	-7.660	8.36e-13	***
math	0.07015	0.01103	6.362	1.38e-09	***
progAcademic	1.08386	0.37272	2.908	0.00406	**
progVocational	0.36981	0.45888	0.806	0.42128	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for quasipoisson family taken to be 1.082366)

Null deviance: 287.67 on 199 degrees of freedom
Residual deviance: 189.45 on 196 degrees of freedom
AIC: NA

Number of Fisher Scoring iterations: 6

● 3. Modelo Binomial Negativa

```
modelinb <- glm.nb(num_awards ~ math + prog, data = awards)
summary(modelinb)
```

Call:

```
glm.nb(formula = num_awards ~ math + prog, data = awards, init.theta = 6.114661779,
       link = log)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-5.29331	0.70416	-7.517	5.60e-14	***
math	0.07107	0.01153	6.165	7.05e-10	***
progAcademic	1.07507	0.36699	2.929	0.0034	**
progVocational	0.36696	0.45230	0.811	0.4172	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(6.1147) family taken to be 1)

Null deviance: 257.93 on 199 degrees of freedom
Residual deviance: 169.76 on 196 degrees of freedom
AIC: 373.81

Caso Práctico

- ¿Cuál es la mejor solución a la sobredispersión?

```
drop_in_dev <- anova(modeliq, modelinb, test = "F"); drop_in_dev
```

```
Model 1: num_awards ~ math + prog
```

```
Model 2: num_awards ~ math + prog
```


	Resid. Df	Resid. Dev	Df	Deviance	F	Pr(>F)
1	196	189.45				
2	196	169.76	0	19.687		

Caso Práctico


● Paso 3: Predicciones del modelo

Calculamos los valores predictivos

```
awards$pred<-predict(fit_glm_2, type = "response")
```



Paso 3: Predicciones del modelo







● Paso 4: Diagnóstico del modelo

- Consiste en revisar los residuos para comprobar el ajuste del modelo.
- Se identifican valores atípicos y puntos influyentes.
- Se evalúa la adecuación de los supuestos del modelo.
- Se comparan modelos alternativos si el ajuste no es correcto.

Caso Práctico

● Paso 4: Diagnóstico del modelo



● Paso 4: Diagnóstico del modelo

Identificación de valores atípicos

```
outliers <- which(abs(residuos_dev) > 2)
cat("Observaciones con residuos altos:", outliers, "\n")
```

Observaciones con residuos altos: 54 157 164 181 199


Identificación de puntos influyentes

```
threshold_cooks <- 4 / (nrow(awards) - length(coef(fit_glm_2)))
outliers <- which(cooks_d > threshold_cooks)
outliers
```

Puntos influyentes identificados: 27 28 36 54 58 87 154 157 181 190 194 199

Caso Práctico

● Paso 4: Diagnóstico del modelo



Caso Práctico

● Paso 4: Diagnóstico del modelo

Eliminación de outliers y ajuste del nuevo modelo

```
awards_clean <- awards[-outliers, ]  
fit_glm_2_clean <- glm(num_awards ~ math + prog, data=awards_clean, family=poisson)  
summary(fit_glm_2_clean)
```

Call:

```
glm(formula = num_awards ~ math + prog, family = poisson, data = awards_clean)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-6.26324	0.80904	-7.742	9.82e-15	***
math	0.07913	0.01239	6.388	1.68e-10	***
progAcademic	1.45359	0.46829	3.104	0.00191	**
progVocational	0.66336	0.55782	1.189	0.23437	


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)


Null deviance: 235.17 on 187 degrees of freedom
Residual deviance: 143.19 on 184 degrees of freedom
AIC: 299.02

Caso Práctico

● Paso 4: Diagnóstico del modelo



Caso Práctico



Resumen de los pasos principales:

1. Ajustar el modelo GLM de Poisson.
2. Revisar si existe sobredispersión (media vs varianza, deviance/GL).
 - a. Soluciones: errores estándar robustos, QuasiPoisson, Binomial Negativa.
3. Realizar predicciones.
4. Hacer diagnosis del modelo:
 - a. Análisis de residuos.
 - b. Identificación de valores atípicos y puntos influyentes.
 - c. Comparación de modelos alternativos.