

Estadística Actuarial Practica 3

Leonel Fernando Nabaza Ruibal

En ATENEA descarga la base de datos dataFREQ.csv, que contiene los datos siguientes:

Variables	Descricion
freq_paielement	Periodicidad pago de la póliza [annuel, mensuel]
langue	Idioma del asegurado [A=Ingles, F=Francés]
type_prof	Profesión del asegurado
alimentation	Hábitos alimenticios
type_territoire	Zona de conducción del asegurado [Urbana, semiurbana, Rural]
utilisation	Tipo de uso del vehículo
presence_alarme	Si el vehículo cuenta o no con alarma
marque_voiture	Marca del vehículo
sexe	sexo del asegurado
cout1	coste del primer siniestro
cout2	coste del segundo siniestro
cout3	coste del tercer siniestro
cout4	coste del cuarto siniestro
nbsin	número de siniestros
exposition	exposición al riesgo en fracciones de año
cout	Suma de los costes de los siniestros
age	Edad del conductor al inicio del período de cobertura en años
duree_permiss	Antigüedad del permiso de conducir

Realiza los siguientes cálculos:

- Haz un descriptivo de los datos.
- Utilizando GLMs, construye un modelo adecuado para la estimación del número de siniestros en función de las características del asegurado. Podéis usar interacciones así como categorizaciones para las variables cuantitativas.
- Utilizando GLMs, construye un modelo adecuado para la estimación de la severidad de los siniestros en función de las características del asegurado. Podéis usar interacciones así como categorizaciones para las variables cuantitativas.
- Calcula para cada asegurado la prima para el año que viene P_i . Para su cálculo, se utilizará el Expected Value Premium Principle (EVPP), según el cual, $P_i = E(S_i) + a \hat{u}E(S_i)$, donde S_i es el coste total de los siniestros de cada asegurado para el año que viene. Podéis asumir un valor $a = 0.1$.

Lectura y preparación de los datos:

```
datos <- read.csv2("dataFREQ.csv",  
                  stringsAsFactors = FALSE,  
                  fileEncoding = "latin1")  
  
str(datos)
```

```
## 'data.frame': 39075 obs. of 18 variables:
## $ freq_paiement : chr "mensuel" "mensuel" "annuel" "annuel" ...
## $ langue : chr "F" "F" "A" "A" ...
## $ type_prof : chr "Technicien" "Technicien" "Technicien" "Technicien" ...
## $ alimentation : chr "Végétarien" "Végétarien" "Carnivore" "Carnivore" ...
## $ type_territoire: chr "Urbain" "Urbain" "Urbain" "Urbain" ...
## $ utilisation : chr "Travail-quotidien" "Travail-quotidien" "Travail-occasionnel" "Travail-occa
## $ presence_alarme: chr "non" "non" "oui" "oui" ...
## $ marque_voiture : chr "VOLKSWAGEN" "VOLKSWAGEN" "NISSAN" "NISSAN" ...
## $ sexe : chr "F" "F" "M" "M" ...
## $ cout1 : num NA NA 280 NA NA ...
## $ cout2 : num NA NA NA NA NA NA NA NA NA NA ...
## $ cout3 : num NA NA NA NA NA NA NA NA NA NA ...
## $ cout4 : num NA NA NA NA NA NA NA NA NA NA ...
## $ nbsin : int 0 0 1 0 0 0 0 0 0 0 ...
## $ exposition : num 0.611 0.663 0.9945 0.874 0.0438 ...
## $ cout : num NA NA 280 NA NA ...
## $ age : int 29 30 42 43 44 44 44 45 46 47 ...
## $ duree_permis : int 10 11 21 22 23 23 23 24 25 26 ...
```

```
summary(datos)
```

```
## freq_paiement      langue      type_prof      alimentation
## Length:39075      Length:39075      Length:39075      Length:39075
## Class :character   Class :character   Class :character   Class :character
## Mode :character    Mode :character    Mode :character    Mode :character
##
##
##
## type_territoire    utilisation      presence_alarme      marque_voiture
## Length:39075      Length:39075      Length:39075      Length:39075
## Class :character   Class :character   Class :character   Class :character
## Mode :character    Mode :character    Mode :character    Mode :character
##
##
##
##      sexe      cout1      cout2      cout3
## Length:39075      Min. : 6.47      Min. : 7.39      Min. : 35.14
## Class :character   1st Qu.: 230.50      1st Qu.: 227.31      1st Qu.: 256.87
## Mode :character    Median : 638.69      Median : 590.82      Median : 835.25
##                    Mean : 7655.25      Mean : 9332.94      Mean : 15109.77
##                    3rd Qu.: 1693.68      3rd Qu.: 1641.67      3rd Qu.: 3812.65
##                    Max. : 594528.00      Max. : 584005.83      Max. : 248309.01
##                    NA's : 33386      NA's : 38343      NA's : 38989
##      cout4      nbsin      exposition      cout
## Min. : 521.4      Min. : 0.0000      Min. : 0.00274      Min. : 6.47
## 1st Qu.: 1751.4      1st Qu.: 0.0000      1st Qu.: 0.44110      1st Qu.: 255.71
## Median : 4573.8      Median : 0.0000      Median : 0.99726      Median : 769.86
## Mean : 17282.0      Mean : 0.1668      Mean : 0.73391      Mean : 9108.83
## 3rd Qu.: 19841.8      3rd Qu.: 0.0000      3rd Qu.: 0.99726      3rd Qu.: 2128.36
## Max. : 61944.8      Max. : 5.0000      Max. : 1.00548      Max. : 665751.99
## NA's : 39067      NA's : 33386
##      age      duree_permis
```

```
## Min. :18.00 Min. : 0.00
## 1st Qu.:36.00 1st Qu.:15.00
## Median :44.00 Median :22.00
## Mean :45.59 Mean :22.15
## 3rd Qu.:54.00 3rd Qu.:30.00
## Max. :87.00 Max. :77.00
##

# Variables cualitativas
vars_factor <- c("freq_paiement", "langue", "type_prof", "alimentation",
                 "type_territoire", "utilisation", "presence_alarme",
                 "marque_voiture", "sexe")

datos[vars_factor] <- lapply(datos[vars_factor], factor)

# Sustituimos NA en costes por 0 para poder hacer descriptivos agregados
datos$cout_total_0 <- ifelse(is.na(datos$cout), 0, datos$cout)

# Categorización de variables cuantitativas
datos$age_cat <- cut(datos$age,
                    breaks = c(17, 25, 35, 45, 55, 65, Inf),
                    labels = c("18-25", "26-35", "36-45",
                               "46-55", "56-65", "66+"),
                    right = TRUE)

datos$permis_cat <- cut(datos$duree_permis,
                      breaks = c(-Inf, 5, 10, 20, 30, Inf),
                      labels = c("0-5", "6-10", "11-20",
                                  "21-30", "31+"),
                      right = TRUE)

# Agrupamos marcas poco frecuentes para evitar demasiados parámetros
tabla_marcas <- sort(table(datos$marque_voiture), decreasing = TRUE)
marcas_principales <- names(tabla_marcas[tabla_marcas >= 300])
datos$marca_grupo <- as.character(datos$marque_voiture)
datos$marca_grupo[!(datos$marca_grupo %in% marcas_principales)] <- "Otras"
datos$marca_grupo <- factor(datos$marca_grupo)

# Evitamos problemas con exposiciones nulas
summary(datos$exposition)

## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 0.00274 0.44110 0.99726 0.73391 0.99726 1.00548

datos <- datos[datos$exposition > 0, ]
```

a) Descriptivo de los datos

```
dim(datos)

## [1] 39075 22

# Resumen de variables numéricas principales
kable(summary(datos[, c("nbsin", "exposition", "cout_total_0",
                       "age", "duree_permis")]))
```

nbsin	exposition	cout_total_0	age	duree_permis
Min. :0.0000	Min. :0.00274	Min. : 0	Min. :18.00	Min. : 0.00
1st Qu.:0.0000	1st Qu.:0.44110	1st Qu.: 0	1st Qu.:36.00	1st Qu.:15.00
Median :0.0000	Median :0.99726	Median : 0	Median :44.00	Median :22.00
Mean :0.1668	Mean :0.73391	Mean : 1326	Mean :45.59	Mean :22.15
3rd Qu.:0.0000	3rd Qu.:0.99726	3rd Qu.: 0	3rd Qu.:54.00	3rd Qu.:30.00
Max. :5.0000	Max. :1.00548	Max. :665752	Max. :87.00	Max. :77.00

Distribuciones de algunas variables cualitativas

```
kable(data.frame(table(datos$freq_paiement)),
      col.names = c("Frecuencia de pago", "Frecuencia"))
```

Frecuencia de pago	Frecuencia
annuel	11625
mensuel	27450

```
kable(data.frame(table(datos$type_territoire)),
      col.names = c("Tipo de territorio", "Frecuencia"))
```

Tipo de territorio	Frecuencia
Rural	1093
Semi-urbain	23366
Urbain	14616

```
kable(data.frame(table(datos$utilisation)),
      col.names = c("Utilización", "Frecuencia"))
```

Utilización	Frecuencia
Loisir	2242
Travail-occasionnel	25966
Travail-quotidien	10867

```
kable(data.frame(table(datos$sexe)),
      col.names = c("Sexo", "Frecuencia"))
```

Sexo	Frecuencia
F	15846
M	23229

Distribución del número de siniestros

```
kable(data.frame(table(datos$nbsin)),
      col.names = c("Número de siniestros", "Frecuencia"))
```

Número de siniestros	Frecuencia
0	33386

Número de siniestros	Frecuencia
1	4957
2	646
3	78
4	7
5	1

```
media_nbsin <- mean(datos$nbsin)
var_nbsin <- var(datos$nbsin)
```

```
media_nbsin
```

```
## [1] 0.1667562
```

```
var_nbsin
```

```
## [1] 0.1866565
```


La variable `nbsin` es una variable de recuento, por lo que es natural utilizar modelos GLM para datos de conteo. En un modelo Poisson se cumple que la media y la varianza coinciden. Si la varianza muestral es claramente superior a la media, puede existir sobredispersión y puede ser conveniente usar una Binomial Negativa o un modelo quasi-Poisson.

```
par(mfrow = c(1, 2))
```


```
hist(datos$nbsin,
      main = "Distribución del número de siniestros",
      xlab = "Número de siniestros",
      breaks = seq(-0.5, max(datos$nbsin) + 0.5, by = 1))
```

```
hist(datos$cout_total_0,
      main = "Distribución del coste total",
      xlab = "Coste total",
      breaks = 50)
```

Distribución del número de siniest



Distribución del coste total



```
par(mfrow = c(1, 1))
```

b) GLM para frecuencia de siniestros

Sea N_i el número de siniestros de la póliza i . En el modelo de Poisson con exposición se supone que

$$N_i \sim \text{Poisson}(\mu_i),$$

con

$$\mu_i = t_i \exp(x_i' \beta)$$

donde t_i es la exposición al riesgo. Equivalentemente,

$$\log(\mu_i) = \log(t_i) + x_i' \beta$$

Por tanto, en R se incluye `offset(log(exposition))`. Modelo:

```
formula_freq <- nbsin ~ freq_paieiment + langue + type_prof + alimentation +
  type_territoire + utilisation + presence_alarme + marca_grupo + sexe +
  age_cat + permis_cat + offset(log(exposition))

modelo_pois <- glm(formula_freq,
  family = poisson(link = "log"),
  data = datos)

summary(modelo_pois)
```

```
##
```

```
## Call:
```

```
## glm(formula = formula_freq, family = poisson(link = "log"), data = datos)
##
## Coefficients:
##
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.804324   0.168060  -4.786 1.70e-06 ***
## freq_paiementmensuel  0.233099   0.029747   7.836 4.65e-15 ***
## langueF         0.185386   0.052425   3.536 0.000406 ***
## type_profAutre    0.076146   0.093450   0.815 0.415164
## type_profAvocat   0.154457   0.073033   2.115 0.034439 *
## type_profHockeyeur 0.023771   0.085170   0.279 0.780167
## type_profInfirmière 0.032591   0.072368   0.450 0.652457
## type_profInformaticien 0.110242   0.079026   1.395 0.163015
## type_profIngénieur 0.113581   0.091920   1.236 0.216587
## type_profMédecin  -0.002596   0.093658  -0.028 0.977891
## type_profProfesseur 0.207776   0.090033   2.308 0.021011 *
## type_profTechnicien 0.046595   0.063828   0.730 0.465391
## alimentationVégétalien 0.362855   0.051898   6.992 2.72e-12 ***
## alimentationVégétarien 0.129177   0.029811   4.333 1.47e-05 ***
## type_territoireSemi-urbain -0.200047   0.069823  -2.865 0.004170 **
## type_territoireUrbain -0.236643   0.082069  -2.883 0.003934 **
## utilisationTravail-occasionnel -0.132875   0.053739  -2.473 0.013413 *
## utilisationTravail-quotidien -0.183036   0.061996  -2.952 0.003153 **
## presence_alarmeuoi -0.413972   0.027333 -15.146 < 2e-16 ***
## marca_grupoAUDI    -0.265000   0.110635  -2.395 0.016608 *
## marca_grupoAutres  -0.305816   0.169154  -1.808 0.070620 .
## marca_grupoBMW     -0.241711   0.110010  -2.197 0.028008 *
## marca_grupoFIAT    -0.174231   0.108976  -1.599 0.109863
## marca_grupoFORD    -0.233702   0.097648  -2.393 0.016697 *
## marca_grupoGM      -0.412663   0.097157  -4.247 2.16e-05 ***
## marca_grupoHONDA   -0.309103   0.097392  -3.174 0.001505 **
## marca_grupoMAZDA   -0.233483   0.114148  -2.045 0.040811 *
## marca_grupoMERCEDES-BENZ -0.313080   0.113404  -2.761 0.005767 **
## marca_grupoMITSUBISHI -0.216655   0.116579  -1.858 0.063106 .
## marca_grupoNISSAN  -0.254932   0.103469  -2.464 0.013746 *
## marca_grupoOtras   -0.274020   0.104610  -2.619 0.008807 **
## marca_grupoPEUGEOT -0.337498   0.100141  -3.370 0.000751 ***
## marca_grupoRENAULT -0.393678   0.096662  -4.073 4.65e-05 ***
## marca_grupoROVER   -0.145054   0.139404  -1.041 0.298092
## marca_grupoSEAT    -0.187597   0.124361  -1.508 0.131430
## marca_grupoSUZUKI  -0.416807   0.160436  -2.598 0.009378 **
## marca_grupoTOYOTA  -0.315016   0.102501  -3.073 0.002117 **
## marca_grupoVOLKSWAGEN -0.225416   0.093365  -2.414 0.015764 *
## marca_grupoVOLVO   -0.571451   0.149924  -3.812 0.000138 ***
## sexeM              0.128787   0.028963   4.447 8.72e-06 ***
## age_cat26-35       -0.064777   0.099670  -0.650 0.515748
## age_cat36-45       -0.042638   0.105315  -0.405 0.685583
## age_cat46-55        0.035943   0.109674   0.328 0.743122
## age_cat56-65       -0.215133   0.118219  -1.820 0.068792 .
## age_cat66+         -0.360160   0.136715  -2.634 0.008429 **
## permis_cat6-10     -0.173496   0.093170  -1.862 0.062584 .
## permis_cat11-20    -0.287677   0.095246  -3.020 0.002525 **
## permis_cat21-30    -0.313986   0.100227  -3.133 0.001732 **
## permis_cat31+      -0.423366   0.107226  -3.948 7.87e-05 ***
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 25545  on 39074  degrees of freedom
## Residual deviance: 24713  on 39026  degrees of freedom
## AIC: 36673
##
## Number of Fisher Scoring iterations: 6
```

Diagnóstico de sobredispersión:

```
disp_deviance <- deviance(modelo_pois) / df.residual(modelo_pois)
disp_pearson <- sum(residuals(modelo_pois, type = "pearson")^2) /
  df.residual(modelo_pois)
```

```
disp_deviance
```

```
## [1] 0.6332352
```

```
disp_pearson
```

```
## [1] 1.436956
```

El valor superior a 1 en la dispersión de Pearson puede sugerir ligera sobredispersión. Por lo tanto, probaremos también con un modelo de distribución Binomial Negativa.

La distribución Binomial Negativa introduce un parámetro de dispersión adicional que permite modelar varianzas superiores a la media.

$$N_i \sim \text{NB}(\mu_i, k),$$

donde k es el parámetro de dispersión.

$$\log(\mu_i) = \log(t_i) + x'_i \beta$$

$$\text{Var}(N_i) = \mu_i + \frac{\mu_i^2}{k}$$

El modelo se ajusta de forma similar al Poisson

```
modelo_nb <- glm.nb(formula_freq, data = datos)
```

```
summary(modelo_nb)
```

```
##
## Call:
## glm.nb(formula = formula_freq, data = datos, init.theta = 2.093670694,
##      link = log)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.79347    0.17820  -4.453 8.48e-06 ***
## freq_paiementmensuel  0.23400    0.03100   7.549 4.39e-14 ***
## langueF         0.18312    0.05493   3.334 0.000856 ***
## type_profAutre    0.07346    0.09841   0.746 0.455406
## type_profAvocat   0.15631    0.07677   2.036 0.041736 *
## type_profHockeyeur 0.02388    0.08912   0.268 0.788782
## type_profInfirmière 0.03502    0.07599   0.461 0.644954
```



```

## type_profInformaticien      0.11113    0.08323    1.335 0.181795
## type_profIngénieur          0.11541    0.09596    1.203 0.229134
## type_profMédecin            0.00304    0.09797    0.031 0.975248
## type_profProfesseur         0.20717    0.09507    2.179 0.029312 *
## type_profTechnicien         0.04654    0.06706    0.694 0.487680
## alimentationVégétalien      0.37481    0.05480    6.839 7.97e-12 ***
## alimentationVégétarien      0.13298    0.03127    4.252 2.12e-05 ***
## type_territoireSemi-urbain  -0.19221    0.07436   -2.585 0.009737 **
## type_territoireUrbain       -0.23354    0.08700   -2.684 0.007269 **
## utilisationTravail-occasionnel -0.13330    0.05685   -2.345 0.019033 *
## utilisationTravail-quotidien -0.18639    0.06534   -2.853 0.004336 **
## presence_alarmeoui          -0.41176    0.02851  -14.443 < 2e-16 ***
## marca_grupoAUDI             -0.27738    0.11739   -2.363 0.018136 *
## marca_grupoAutres           -0.32742    0.17877   -1.832 0.067021 .
## marca_grupoBMW              -0.25317    0.11681   -2.167 0.030199 *
## marca_grupoFIAT             -0.18186    0.11570   -1.572 0.115994
## marca_grupoFORD             -0.24624    0.10381   -2.372 0.017690 *
## marca_grupoGM               -0.42350    0.10317   -4.105 4.05e-05 ***
## marca_grupoHONDA            -0.32056    0.10346   -3.098 0.001945 **
## marca_grupoMAZDA            -0.23969    0.12076   -1.985 0.047158 *
## marca_grupoMERCEDES-BENZ    -0.32856    0.12011   -2.736 0.006226 **
## marca_grupoMITSUBISHI       -0.22817    0.12376   -1.844 0.065220 .
## marca_grupoNISSAN           -0.26778    0.10978   -2.439 0.014719 *
## marca_grupoOtras            -0.28565    0.11102   -2.573 0.010080 *
## marca_grupoPEUGEOT          -0.34942    0.10628   -3.288 0.001010 **
## marca_grupoRENAULT          -0.40523    0.10267   -3.947 7.92e-05 ***
## marca_grupoROVER            -0.15879    0.14811   -1.072 0.283675
## marca_grupoSEAT             -0.20669    0.13213   -1.564 0.117757
## marca_grupoSUZUKI           -0.43755    0.16864   -2.595 0.009470 **
## marca_grupoTOYOTA           -0.32967    0.10869   -3.033 0.002420 **
## marca_grupoVOLKSWAGEN       -0.23692    0.09940   -2.383 0.017150 *
## marca_grupoVOLVO            -0.58120    0.15653   -3.713 0.000205 ***
## sexeM                       0.12829    0.03034    4.229 2.35e-05 ***
## age_cat26-35                -0.05912    0.10564   -0.560 0.575735
## age_cat36-45                -0.03743    0.11150   -0.336 0.737087
## age_cat46-55                0.04429    0.11606    0.382 0.702764
## age_cat56-65                -0.20764    0.12475   -1.664 0.096023 .
## age_cat66+                  -0.35613    0.14361   -2.480 0.013147 *
## permis_cat6-10              -0.17692    0.09857   -1.795 0.072669 .
## permis_cat11-20             -0.29147    0.10065   -2.896 0.003783 **
## permis_cat21-30             -0.32088    0.10587   -3.031 0.002438 **
## permis_cat31+               -0.42956    0.11309   -3.798 0.000146 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(2.0937) family taken to be 1)
##
## Null deviance: 22761 on 39074 degrees of freedom
## Residual deviance: 21996 on 39026 degrees of freedom
## AIC: 36559
##
## Number of Fisher Scoring iterations: 1
##
##

```

```
##           Theta: 2.094
##         Std. Err.: 0.231
##
## 2 x log-likelihood: -36459.019
```

y comparamos AIC de ambos modelos:

```
comparacion_freq <- data.frame(
  Modelo = c("Poisson", "Binomial Negativa"),
  AIC = c(AIC(modelo_pois), AIC(modelo_nb)),
  Deviance = c(deviance(modelo_pois), deviance(modelo_nb)),
  GL_residuales = c(df.residual(modelo_pois), df.residual(modelo_nb))
)

kable(comparacion_freq, digits = 4)
```

Modelo	AIC	Deviance	GL_residuales
Poisson	36672.80	24712.64	39026
Binomial Negativa	36559.02	21995.78	39026

El modelo Poisson presenta una ligera sobredispersión, ya que la razón de dispersión basada en residuos de Pearson es aproximadamente 1.44.

Aunque esta desviación no es excesiva, la comparación mediante el criterio AIC muestra que el modelo Binomial Negativa proporciona un mejor ajuste a los datos:

$$AIC_{NB} = 36559.02 < AIC_{Poisson} = 36672.80.$$

Por tanto, el modelo Binomial Negativa se considera más adecuado para modelizar la frecuencia de siniestros, ya que permite incorporar una varianza superior a la media y capturar mejor la heterogeneidad entre asegurados.

Calcular ahora las dispersiones para la Binomial Negativa:

```
disp_deviance_nb <- deviance(modelo_nb) / df.residual(modelo_nb)
disp_pearson_nb <- sum(residuals(modelo_nb, type = "pearson")^2) / df.residual(modelo_nb)
disp_deviance_nb
```

```
## [1] 0.5636187
```

```
disp_pearson_nb
```

```
## [1] 1.34685
```

Observamos que obtenemos valores de dispersión más controlados.

Asignamos ya el modelo ganador:

```
if (AIC(modelo_nb) < AIC(modelo_pois)) {
  modelo_freq_final <- modelo_nb
  nombre_modelo_freq <- "Binomial Negativa"
} else {
  modelo_freq_final <- modelo_pois
  nombre_modelo_freq <- "Poisson"
}

nombre_modelo_freq
```

```
## [1] "Binomial Negativa"
```

Predicción de frecuencia del año siguiente

Para calcular la prima del próximo año se predice el número esperado de siniestros suponiendo exposición anual igual a 1.

```
datos_pred <- datos
datos_pred$exposition <- 1

datos$freq_pred <- predict(modelo_freq_final,
                           newdata = datos_pred,
                           type = "response")

summary(datos$freq_pred)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.06018 0.16928 0.22027 0.23250 0.28527 0.71688
```

GLM para severidad de siniestros

La severidad representa el coste medio por siniestro. Como sólo existe severidad cuando hay al menos un siniestro, se trabaja con las pólizas tales que $\text{nbsin} > 0$. Definimos:

$$Y_i = \frac{\text{cout}_i}{N_i}, \quad N_i > 0.$$

Dado que la severidad es positiva, asimétrica y con cola derecha, un modelo Gamma con enlace logarítmico es adecuado:

$$Y_i \sim \text{Gamma}(\mu_i, \phi),$$
$$\log(\mu_i) = x_i' \gamma.$$

El enlace log permite obtener una estructura multiplicativa en los factores tarifarios.

```
datos_sev <- subset(datos, nbsin > 0 & !is.na(cout) & cout > 0)


datos_sev$severidad <- datos_sev$cout / datos_sev$nbsin

summary(datos_sev$severidad)

##      Min.   1st Qu.   Median     Mean   3rd Qu.     Max.
##      6.47    241.72    682.28   7862.14   1845.11  594528.00

hist(datos_sev$severidad,
     main = "Distribución de la severidad",
     xlab = "Coste medio por siniestro",
     breaks = 50)
```

Distribución de la severidad



Modelo:

```
formula_sev <- severidad ~ freq_paiement + langue + type_prof + alimentation +
  type_territoire + utilisation + presence_alarme + marca_grupo + sexe +
  age_cat + permis_cat

modelo_gamma <- glm(formula_sev,
  family = Gamma(link = "log"),
  data = datos_sev)

summary(modelo_gamma)
```

```
##
## Call:
## glm(formula = formula_sev, family = Gamma(link = "log"), data = datos_sev)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    9.469143   0.580758  16.305 < 2e-16 ***
## freq_paiementmensuel -0.110572   0.102646  -1.077  0.28143
## langueF        -0.085629   0.171636  -0.499  0.61787
## type_profAutre    0.745961   0.328025   2.274  0.02300 *
## type_profAvocat    0.262937   0.253699   1.036  0.30005
## type_profHockeyeur  0.242827   0.296104   0.820  0.41221
## type_profInfirmière  0.500275   0.251877   1.986  0.04706 *
## type_profInformaticien -0.137781   0.275910  -0.499  0.61754
## type_profIngénieur  0.389269   0.323549   1.203  0.22898
```

```

## type_profMédecin          0.065777  0.325773  0.202  0.83999
## type_profProfesseur       0.522675  0.318398  1.642  0.10073
## type_profTechnicien       0.531213  0.222008  2.393  0.01675 *
## alimentationVégétalien    0.589938  0.183282  3.219  0.00129 **
## alimentationVégétarien    0.105209  0.102756  1.024  0.30594
## type_territoireSemi-urbain -0.178323  0.248509 -0.718  0.47305
## type_territoireUrbain     -0.312183  0.283182 -1.102  0.27033
## utilisationTravail-occasionnel -0.473171  0.185837 -2.546  0.01092 *
## utilisationTravail-quotidien -0.269109  0.214879 -1.252  0.21049
## presence_alarmeuoi        -0.241488  0.094475 -2.556  0.01061 *
## marca_grupoAUDI           -0.346622  0.383504 -0.904  0.36612
## marca_grupoAutres         -1.601363  0.596416 -2.685  0.00727 **
## marca_grupoBMW            -0.190022  0.382793 -0.496  0.61963
## marca_grupoFIAT           -0.297744  0.377088 -0.790  0.42980
## marca_grupoFORD           -0.223621  0.337015 -0.664  0.50702
## marca_grupoGM             -0.136073  0.336589 -0.404  0.68603
## marca_grupoHONDA          -0.162251  0.335399 -0.484  0.62858
## marca_grupoMAZDA           0.156548  0.394624  0.397  0.69160
## marca_grupoMERCEDES-BENZ  -0.601018  0.394126 -1.525  0.12733
## marca_grupoMITSUBISHI     -0.511731  0.407664 -1.255  0.20943
## marca_grupoNISSAN         -0.004515  0.358051 -0.013  0.98994
## marca_grupoOtras          0.123903  0.364123  0.340  0.73366
## marca_grupoPEUGEOT        -0.062970  0.344952 -0.183  0.85516
## marca_grupoRENAULT        -0.229902  0.334463 -0.687  0.49187
## marca_grupoROVER           0.023950  0.491441  0.049  0.96113
## marca_grupoSEAT           -0.695514  0.436224 -1.594  0.11090
## marca_grupoSUZUKI          0.712518  0.572972  1.244  0.21372
## marca_grupoTOYOTA          -0.278655  0.353390 -0.789  0.43043
## marca_grupoVOLKSWAGEN     -0.123510  0.323315 -0.382  0.70247
## marca_grupoVOLVO           0.025136  0.512458  0.049  0.96088
## sexeM                     -0.033199  0.099968 -0.332  0.73983
## age_cat26-35              -0.471340  0.351074 -1.343  0.17947
## age_cat36-45              -0.536952  0.371678 -1.445  0.14861
## age_cat46-55              -0.591203  0.387409 -1.526  0.12706
## age_cat56-65              -0.497652  0.417334 -1.192  0.23313
## age_cat66+                -0.364458  0.485415 -0.751  0.45279
## permis_cat6-10            0.330508  0.326093  1.014  0.31085
## permis_cat11-20           0.532908  0.333562  1.598  0.11018
## permis_cat21-30           0.559763  0.352072  1.590  0.11191
## permis_cat31+             0.579727  0.376116  1.541  0.12329
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 10.49003)
##
## Null deviance: 24902 on 5688 degrees of freedom
## Residual deviance: 24154 on 5640 degrees of freedom
## AIC: 104873
##
## Number of Fisher Scoring iterations: 20

```

El otro modelo con el que podemos comparar es con una lognormal:

$$\log(Y_i) \sim N(\mu_i, \sigma^2),$$

$$\log(Y_i) = x_i' \beta + \varepsilon_i,$$

$$\varepsilon_i \sim N(0, \sigma^2)$$

```
modelo_lognormal <- lm(log(severidad) ~ freq_paiement + langue + type_prof +
  alimentation + type_territoire + utilisation +
  presence_alarme + marca_grupo + sexe +
  age_cat + permis_cat,
  data = datos_sev)
```

```
summary(modelo_lognormal)
```

```
##
## Call:
## lm(formula = log(severidad) ~ freq_paiement + langue + type_prof +
##      alimentation + type_territoire + utilisation + presence_alarme +
##      marca_grupo + sexe + age_cat + permis_cat, data = datos_sev)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.2500 -1.2604 -0.2523  0.7488  6.5077
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      6.45356    0.33722   19.137 < 2e-16 ***
## freq_paiementmensuel  0.06185    0.05960    1.038 0.299438
## langueF           0.11569    0.09966    1.161 0.245782
## type_profAutre     -0.03827    0.19047   -0.201 0.840751
## type_profAvocat     -0.01254    0.14731   -0.085 0.932183
## type_profHockeyeur   0.10107    0.17194    0.588 0.556676
## type_profInfirmière  0.17019    0.14625    1.164 0.244613
## type_profInformaticien -0.10656    0.16021   -0.665 0.505981
## type_profIngénieur  -0.09587    0.18787   -0.510 0.609847
## type_profMédecin     0.05547    0.18916    0.293 0.769342
## type_profProfesseur  0.10412    0.18488    0.563 0.573326
## type_profTechnicien  0.07883    0.12891    0.612 0.540877
## alimentationVégétalien  0.41198    0.10642    3.871 0.000110 ***
## alimentationVégétarien  0.15548    0.05967    2.606 0.009191 **
## type_territoireSemi-urbain -0.16766    0.14430   -1.162 0.245341
## type_territoireUrbain  -0.13622    0.16443   -0.828 0.407473
## utilisationTravail-occasionnel -0.05586    0.10791   -0.518 0.604721
## utilisationTravail-quotidien  0.01842    0.12477    0.148 0.882644
## presence_alarmeoui    0.04792    0.05486    0.873 0.382456
## marca_grupoAUDI      -0.01737    0.22268   -0.078 0.937819
## marca_grupoAutres    -0.41223    0.34631   -1.190 0.233963
## marca_grupoBMW       0.16560    0.22227    0.745 0.456272
## marca_grupoFIAT      0.14056    0.21896    0.642 0.520932
## marca_grupoFORD      0.06930    0.19569    0.354 0.723272
## marca_grupoGM        0.26557    0.19544    1.359 0.174259
## marca_grupoHONDA     0.31465    0.19475    1.616 0.106226
## marca_grupoMAZDA     0.43729    0.22914    1.908 0.056394 .
## marca_grupoMERCEDES-BENZ 0.17310    0.22885    0.756 0.449462
## marca_grupoMITSUBISHI 0.13144    0.23671    0.555 0.578746
## marca_grupoNISSAN    0.30115    0.20791    1.449 0.147529
## marca_grupoOtras     0.16892    0.21143    0.799 0.424366
```

```
## marca_grupoPEUGEOT      0.28593    0.20030    1.428 0.153485
## marca_grupoRENAULT      0.13674    0.19421    0.704 0.481409
## marca_grupoROVER        0.53160    0.28536    1.863 0.062525 .
## marca_grupoSEAT        -0.04452    0.25330   -0.176 0.860480
## marca_grupoSUZUKI       1.10881    0.33270    3.333 0.000865 ***
## marca_grupoTOYOTA       0.16925    0.20520    0.825 0.409511
## marca_grupoVOLKSWAGEN   0.07473    0.18774    0.398 0.690618
## marca_grupoVOLVO        0.70758    0.29756    2.378 0.017445 *
## sexeM                   -0.05861    0.05805   -1.010 0.312681
## age_cat26-35            -0.15351    0.20385   -0.753 0.451460
## age_cat36-45            -0.05594    0.21582   -0.259 0.795491
## age_cat46-55            -0.09919    0.22495   -0.441 0.659284
## age_cat56-65            -0.08664    0.24233   -0.358 0.720701
## age_cat66+              0.02255    0.28186    0.080 0.936224
## permis_cat6-10          0.22392    0.18935    1.183 0.237027
## permis_cat11-20         0.11960    0.19369    0.618 0.536925
## permis_cat21-30         0.19216    0.20443    0.940 0.347274
## permis_cat31+           0.28191    0.21840    1.291 0.196812
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.881 on 5640 degrees of freedom
## Multiple R-squared:  0.01558,    Adjusted R-squared:  0.007197
## F-statistic: 1.859 on 48 and 5640 DF,  p-value: 0.0003039
```

Comparación de modelos:

```
comparacion_sev <- data.frame(
  Modelo = c("Gamma log-link", "Lognormal"),
  AIC = c(AIC(modelo_gamma), AIC(modelo_lognormal))
)

kable(comparacion_sev, digits = 4)
```

Modelo	AIC
Gamma log-link	104872.88
Lognormal	23382.06

Observamos que la Lognormal tiene un menor AIC, por lo que se considera un mejor modelo para la severidad. Asignamos el modelo ganador:

```
if (AIC(modelo_lognormal) < AIC(modelo_gamma)) {
  modelo_sev_final <- modelo_lognormal
  nombre_modelo_sev <- "Lognormal"
} else {
  modelo_sev_final <- modelo_gamma
  nombre_modelo_sev <- "Gamma log-link"
}
nombre_modelo_sev
```

```
## [1] "Lognormal"
```

Predicción de severidad del año siguiente

```
datos$sev_pred <- predict(modelo_sev_final,
                          newdata = datos,
                          type = "response")
```

```
summary(datos$sev_pred)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    5.806   6.634   6.766   6.787   6.911   8.359
```

d) Cálculo de la prima mediante EVPP

La prima pura esperada se calcula mediante un modelo en dos partes:

$$E(S_i) = E(N_i) \cdot E(Y_i|N_i > 0),$$

donde: - $E(N_i)$ se obtiene del modelo de frecuencia (Binomial Negativa). - $E(Y_i|N_i > 0)$ se obtiene del modelo de severidad (Lognormal).

Aplicando el Expected Value Premium Principle:

$$P_i = (1 + a)E(S_i),$$

con $a = 0.1$.

```
a <- 0.1
```

```
datos$prima_pura <- datos$freq_pred * datos$sev_pred
datos$prima_evpp <- (1 + a) * datos$prima_pura
```

```
summary(datos$prima_pura)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.4245  1.1444  1.4953  1.5781  1.9375  4.8607
```

```
summary(datos$prima_evpp)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.4669  1.2589  1.6448  1.7359  2.1313  5.3468
```

```
resultado_primas <- data.frame(
  id = 1:nrow(datos),
  freq_paiement = datos$freq_paiement,
  type_prof = datos$type_prof,
  type_territoire = datos$type_territoire,
  utilisation = datos$utilisation,
  sexe = datos$sexe,
  age = datos$age,
  duree_permis = datos$duree_permis,
  frecuencia_predicha = datos$freq_pred,
  severidad_predicha = datos$sev_pred,
  prima_pura = datos$prima_pura,
  prima_evpp = datos$prima_evpp
)
```

```
kable(head(resultado_primas, 20), digits = 4)
```


id	freq_paiement	type_prof	type_territoire	utilisation	sexe	age	duree_permission	frequence_premiale	premiere_premiale	prima_evpp
1	mensuel	Technicien	Urbain	Travail-quotidien	F	29	10	0.3363	6.8927	2.3181
2	mensuel	Technicien	Urbain	Travail-quotidien	F	30	11	0.2999	6.7884	2.0359
3	annuel	Technicien	Urbain	Travail-occasionnel	M	42	21	0.1322	6.7670	0.8947
4	annuel	Technicien	Urbain	Travail-occasionnel	M	43	22	0.1322	6.7670	0.8947
5	annuel	Technicien	Urbain	Travail-occasionnel	M	44	23	0.1322	6.7670	0.8947
6	annuel	Technicien	Urbain	Travail-occasionnel	M	44	23	0.1322	6.7670	0.8947
7	annuel	Technicien	Urbain	Travail-occasionnel	M	44	23	0.1322	6.7670	0.8947
8	annuel	Technicien	Urbain	Travail-occasionnel	M	45	24	0.1322	6.7670	0.8947
9	annuel	Technicien	Urbain	Travail-occasionnel	M	46	25	0.1435	6.7237	0.9647
10	annuel	Technicien	Urbain	Travail-occasionnel	M	47	26	0.1435	6.7237	0.9647
11	annuel	Technicien	Urbain	Travail-occasionnel	M	48	27	0.1435	6.7237	0.9647
12	annuel	Technicien	Urbain	Travail-occasionnel	M	48	27	0.2166	6.6758	1.4458
13	annuel	Technicien	Urbain	Travail-occasionnel	M	50	29	0.2166	6.6758	1.4458
14	mensuel	Technicien	Semi-urbain	Travail-occasionnel	M	49	20	0.2217	6.8108	1.5098
15	mensuel	Technicien	Semi-urbain	Travail-occasionnel	M	50	21	0.2153	6.8833	1.4817
16	mensuel	Technicien	Semi-urbain	Travail-occasionnel	M	51	22	0.2153	6.8833	1.4817
17	mensuel	Technicien	Semi-urbain	Travail-occasionnel	M	51	22	0.2153	6.8833	1.4817
18	mensuel	Technicien	Semi-urbain	Travail-occasionnel	M	52	23	0.3249	6.8354	2.2210
19	mensuel	Technicien	Semi-urbain	Travail-occasionnel	M	52	23	0.3249	6.8354	2.2210
20	mensuel	Technicien	Semi-urbain	Travail-occasionnel	M	53	24	0.3249	6.8354	2.2210

Escribimos los resultados en un fichero:

```
write.csv2(resultado_primas,
            file = "primas_practica3.csv",
            row.names = FALSE)
```